

具身智能行业和技术发展调研报告 v0.3 Z2a 多 模态与基础模型基础

个人学习与研究用途

2026-07-14

装配说明

本入口用于第 14 - 17 章的批次构建，不替代全书 `main.tex`。

目录

第十四章 Transformer与动作序列建模	1
14.1 注意力计算：内容寻址而非时间模型本身	1
14.2 机器人序列如何组织	1
14.3 自回归目标与动作序列的特殊性	2
14.4 复杂度、KV cache 与实时性	2
14.5 文本序列与动作序列的证据差异	3
14.6 知识小结与综述判断	3
第十五章 多模态编码器、连接器与接口	4
15.1 不同模态解决不同可观测性问题	4
15.2 视觉、三维、触觉与本体编码	4
15.3 连接器内部到底发生什么	5
15.4 prefix、交错与 latent slot 接口	5
15.5 信息损失、模态鸿沟与时间对齐	6
15.6 知识小结与综述判断	6
第十六章 从 VLM 到 VLA：语义落地与动作接口	8
16.1 视觉语言预训练迁移了什么	8
16.2 grounding、可供性与本体状态	8
16.3 动作头、低层控制与闭环缺口	9
16.4 安全门与失败恢复	9
16.5 与 VLA 系统综述的边界	10
16.6 知识小结与综述判断	10
第十七章 上下文、外部记忆与长时程任务	11

17.1 三种时间尺度需要三种状态	11
17.2 历史压缩、事件摘要与检索	11
17.3 结构化任务状态与恢复	12
17.4 上下文预算与写入治理	12
17.5 错误记忆与长时程评测	13
17.6 知识小结与综述判断	13
References	14

第十四章 Transformer与动作序列建模

14.1 注意力计算：内容寻址而非时间模型本身

给定序列表示 $X \in \mathbb{R}^{L \times d}$ ，线性投影得到 $Q = XW_Q, K = XW_K, V = XW_V$ ，scaled dot-product attention 为

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V. \quad (14.1)$$

M 可屏蔽未来 token 或无效 padding。除以 $\sqrt{d_k}$ 是为了避免维度增大时点积方差过大，使 softmax 过早饱和。多头注意力让不同子空间独立计算，再拼接投影。Transformer 用自注意力与前馈网络取代循环结构，但顺序必须由位置编码、因果掩码或时间戳显式提供^[1]。

注意力权重不是因果解释。一个 token 权重高只说明当前计算中的相似性和归一化结果；层间残差、MLP 和后续头还会改变贡献。机器人报告不应把热力图直接写成“模型关注了正确物体”的行为证据。

14.2 机器人序列如何组织

机器人输入可能包括语言 l 、图像 patch v_t 、本体状态 p_t 、触觉 h_t 和历史动作 a_{t-1} 。一种交错序列为

$$[l_{1:m}, v_0, p_0, h_0, a_0, v_1, p_1, h_1, a_1, \dots]. \quad (14.2)$$

另一种做法先在每个时刻融合多模态，再把时刻 latent 组成时间序列。前者保留细粒度交互但 token 多，后者计算便宜但连接器成为信息瓶颈。




图 14.1：机器人因果序列的最小时间轴。作者教学绘制；每个观测块还必须携带采样时间，排列顺序不能修复时间戳错误。

位置编码只区分槽位，不等于物理时间。相机 30 Hz、本体 200 Hz、触觉 1 kHz

时，按到达顺序拼接会把通信抖动误写成动作因果。应先按测量时间对齐或保留连续时间嵌入，并标注缺帧、插值和状态新鲜度。

14.3 自回归目标与动作序列的特殊性

因果模型最小化

$$\mathcal{L}_{\text{AR}} = - \sum_{i=1}^L \log p_{\theta}(y_i | y_{<i}, c). \quad (14.3)$$

文本 token 错误通常仍可在后续文本中修正；动作 token 会改变世界，后续条件分布随之变化。动作还具有连续单位、速度/加速度约束和不可逆风险。因而相同的交叉熵并不意味着相同的闭环代价。

连续动作可直接回归，也可量化成离散 token。RT-1 把机器人动作离散化并与图像/语言条件一起建模^[2]。离散化便于复用语言模型头，但每维 bin 宽决定物理分辨率；独立量化各维又忽略关节/末端耦合。第 12 章讨论扩散和流式连续动作，第 23 章比较代表性 VLA 的动作接口。

teacher forcing 训练时使用真实前缀，部署时使用模型先前输出，形成 exposure bias。动作块减少自回归步数，却延长开环执行窗口。评估必须报告 rollout 成功和恢复，而非只给 token 准确率。

14.4 复杂度、KV cache 与实时性

标准全注意力计算和注意力矩阵内存约为 $O(L^2d)$ 与 $O(L^2)$ 。自回归推理若缓存各层历史 key/value，新 token 不必重算全部前缀，但缓存内存约随 $O(N_{\text{layer}}Ld)$ 增长。多相机 patch、长历史和大模型层数会快速耗尽显存。

设控制频率 50 Hz，即周期 20 ms；端到端推理 100 ms 意味着动作使用至少 5 个周期前的状态。即使平均延迟 18 ms，99.9 分位 80 ms 也可能触发接触失败。应分别测量编码、连接器、解码、后处理和通信时间，并报告尾延迟。

Listing 14.1: 带时间戳与 KV cache 失效条件的因果推理教学伪代码

```

1 tokens, stamps = encode_new_observations(sensor_packet)
2 if stale(stamps) or calibration_version_changed():
3     kv_cache.clear(); controller.safe_hold()
4 tokens = append_time_embeddings(tokens, stamps)
5 logits, kv_cache = model.decode(tokens, kv_cache=kv_cache)
6 action = project_units_limits(decode_action(logits))
7 if inference_deadline_missed(): use_backup_controller()
8 else: execute(action)

```

缓存不是永远有效的。机器人重定位、任务切换、外参更新或安全回滚后，旧 KV 中的状态语义可能与当前世界冲突。需要缓存版本、任务 ID 和物理状态重置条件。

14.5 文本序列与动作序列的证据差异

表 14.1: 文本与机器人动作序列的关键差异

维度	文本生成	动作生成
token 语义	离散符号，错误多可继续阅读	连续物理量或量化量，改变环境状态
时间	序列位置常足够	测量时间、控制周期和延迟直接影响可执行性
约束	语法/事实约束为主	关节、碰撞、动力学、接触与安全约束
反馈	输出后通常无物理反馈	每步观测闭环，状态分布由动作改变
评测	困惑度、准确率、偏好	任务成功、约束违反、延迟、恢复与损坏

14.6 知识小结与综述判断

知识小结：注意力做内容寻址，位置/时间编码与掩码赋予顺序；自回归目标预测下一个 token；KV cache 用内存换取增量推理。机器人序列还必须组织多率传感、动作单位和状态时间戳。

综述判断：把动作写成 token 只统一了软件接口，没有消除物理约束。Transformer 的主要价值是灵活融合长序列条件；其主要工程代价是 token 预算、尾延迟和缓存一致性。任何“实时”结论都应给出完整控制周期和尾分位，而不是只报模型前向平均值。

第十五章 多模态编码器、连接器与接口

15.1 不同模态解决不同可观测性问题

RGB提供纹理与语义，深度/点云提供几何，触觉提供局部接触形变与滑移，本体状态提供关节和执行器信息，音频可提示碰撞或电机异常。多模态并非“信号越多越好”：每种传感器都有坐标系、采样率、延迟和失效模式。编码器的任务是把原始信号变成下游可用特征，连接器则把异构特征映射到共享模型接受的 token 或 latent 接口。

15.2 视觉、三维、触觉与本体编码

ViT 把图像划分为 $P \times P$ patch。对 $H \times W$ 图像，token 数为

$$N_v = \frac{H W}{P P}. \quad (15.1)$$

若 $H = W = 224, P = 16$ ，单帧有 196 个 patch token；两相机、8 帧即 3136 个视觉 token，尚未计入语言和动作。ViT 说明了 patch 序列进入 Transformer 的基本接口^[3]；CLIP 用图文对比预训练获得开放词汇语义对齐^[4]，但其全局语义不保证毫米级几何和接触状态。

点云编码需处理排列不变性、密度和坐标系；体素/稀疏卷积适合规则空间索引，点式网络保留不规则采样。触觉图像看似 RGB，物理含义却来自弹性体形变、照明和接触标定。GelSight 类传感器从高分辨率表面形变估计几何和力^[5]；直接套用自然图像增强可能删除微小滑移纹理。本体状态通常经 MLP/傅里叶特征编码，但单位、关节顺序和归一化版本必须写入接口。

表 15.1: 模态、编码目标与不可互换的失效

模态	主要信息	常见编码	时间/坐标要求	典型失效
RGB	纹理、语义	CNN/ViT	相机内外参、曝光时间	光照、遮挡、域偏移
深度/点云	几何、距离	点网络、体素/稀疏卷积	深度标定、世界/机体系	空洞、反光、稀疏
触觉	接触形变、滑移	CNN/时序编码器	传感器局部系、接触时刻	漂移、磨损、饱和
本体状态	关节、速度、力矩	MLP/时序编码	关节顺序、单位、控制时间	编码器回零、延迟
音频	冲击、摩擦、电机声	频谱/音频 Transformer	麦克风同步、窗口	环境噪声、混响

15.3 连接器内部到底发生什么

最简单的线性/MLP adapter对每个视觉 token 投影到语言模型维度,保留 token 数。Cross-attention 连接器用少量可学习 query Q_l 读取大量模态特征 K_m, V_m :

$$Z = \text{softmax} \left(\frac{Q_l K_m^\top}{\sqrt{d}} \right) V_m. \quad (15.2)$$

若 query 数为 $N_l \ll N_m$, 它把 N_m 个输入压成 N_l 个 latent。Perceiver 用 latent bottleneck 迭代读取高维输入^[6]; BLIP-2 的 Q-Former 用可学习 query 在冻结图像编码器与冻结语言模型之间提取视觉信息^[7]。




图 15.1: latent-query 连接器的内部计算。作者依据 Perceiver/Q-Former 的共同 cross-attention 结构改绘^[6-7]。

压缩不是免费。 N_l 太少会丢失小物体或接触瞬间,太多则占据上下文和计算。query 训练目标若只受语言描述监督,可能保留“杯子”语义而丢掉杯沿姿态。连接器是否有效必须按下游定位、动作和接触任务评估。

15.4 prefix、交错与 latent slot 接口

视觉前缀把所有视觉 token 放在语言/动作之前,便于因果解码但弱化帧间对应; interleaving 按时间交错观测和动作,保留轨迹结构但序列更长; latent slot

固定每帧或每模态的 token 数，计算稳定但信息瓶颈更强；action token 把动作离散或嵌入同一词表/隐藏空间。

上下文预算为 $L_{\max}$ 时，若语言占 L_l 、每帧视觉占 L_v 、本体/触觉占 L_s ，可保留帧数近似为

$$T_{\max} = \left\lfloor \frac{L_{\max} - L_l - L_{\text{out}}}{L_v + L_s} \right\rfloor. \quad (15.3)$$

例如 $L_{\max} = 4096, L_l = 256, L_{\text{out}} = 256, L_v = 196, L_s = 8$ ，只能容纳 17 帧。提高相机分辨率会直接缩短时间历史。

Listing 15.1: 最小 latent-query 连接器教学伪代码

```

1 features, stamps = modality_encoder(raw_sensor)
2 assert calibration_and_time_valid(stamps)
3 keys = key_projection(features)
4 values = value_projection(features)
5 queries = learned_queries.expand(batch_size, num_latents, dim)
6 latents = softmax(queries @ keys.T / sqrt(dim)) @ values
7 latents = output_projection(latents)
8 return latents, stamps, modality_valid_mask

```

真实实现还需多头、残差、归一化和掩码；伪代码强调连接器输出必须保留时间戳和有效性，而不能只返回浮点张量。

15.5 信息损失、模态鸿沟与时间对齐

模态对齐常用对比或配对损失，但“语义靠近”不等于几何同构。文本“轻轻放下”没有唯一力轨迹，触觉接触也没有唯一语言描述。共享 latent 需要允许一对多关系，并由动作/任务损失补充约束。

传感到达时间不同会形成虚假跨模态关联。相机看到未接触，触觉已报告碰撞时，简单拼接让模型学到矛盾状态。应按测量时间对齐、保留延迟分布，并对缺失模态训练显式 mask。模态 dropout 只能提高已知缺失的鲁棒性，不能修复错误标定或未检测的陈旧数据。

15.6 知识小结与综述判断

知识小结：编码器从各模态提取任务相关特征；adapter 改变维度，Q-Former 与 Perceiver 类连接器用 latent query 压缩大量特征；prefix、交错和 slot 决定 token 与时间组织。token 预算把空间分辨率、相机数与历史长度直接耦合。

综述判断：结构图中的“connector”不是无损电缆，而是决定信息丢失和训练

梯度的瓶颈。论文比较应报告输入 token、输出 latent、监督目标和下游任务，而不能只说“使用轻量适配器”。对机器人而言，时间戳、坐标系与失效 mask 与 hidden size 同等重要。

第十六章 从 VLM 到 VLA：语义落地与动作接口

16.1 视觉语言预训练迁移了什么

图文预训练可迁移物体类别、属性、关系、开放词汇检索和语言组合先验。CLIP 的对比目标把配对图文拉近，使视觉特征能被自然语言查询^[4]；PaLM-E 把连续传感表示注入语言模型，探索具身多模态推理^[8]。这些能力可帮助理解“把红杯放到左侧托盘”，却不自动给出红杯六自由度姿态、机器人可达构型、抓取力和接触恢复。

VLA 必须把语义条件落到动作分布：

$$p(a_{t:t+H} \mid I_{\leq t}, l, p_{\leq t}, h_{\leq t}, e), \quad (16.1)$$

其中 I 是视觉、 l 是语言、 p 是本体状态、 h 是历史/触觉、 e 是本体与控制接口。遗漏 e 会把“同一动作”误认为能跨机器人直接执行。




图 16.1：从语义到闭环动作的五个证据门。作者教学绘制；任一门失败都不能由“语义理解正确”替代。

16.2 grounding、可供性与本体状态

grounding 要把词语对应到图像区域、三维对象或持续跟踪 ID。检测框不足以抓取：还需姿态、遮挡、几何和不确定性。对象在图像中可见也不等于机器人可达；可供性取决于本体、夹爪、障碍和当前状态。

SayCan 将语言模型给出的技能相关性与机器人价值/可供性结合，使语言上合理但机器人做不到的技能被降权^[9]。抽象地可写为

$$s(k \mid l, s) = \log p_{\text{LM}}(k \mid l) + \lambda \log A(k \mid s, e), \quad (16.2)$$

k 为技能， A 是在当前状态和本体上成功的可供性。若语言概率为 0.9、可供性为 0，组合仍必须禁止执行；给 A 加数值下限时尤其要避免把不可行动作重新赋予非零机会。

本体状态提供关节、末端、夹爪和控制模式。只看图像时，相同场景可能对应完全不同动作：机械臂正在向前运动还是静止、夹爪是否已闭合、上一动作是否被安全层截断，都决定下一步。状态还必须带单位、坐标系和时间戳。

16.3 动作头、低层控制与闭环缺口

VLA可输出离散动作 token、连续末端增量、关节目标、动作块、技能调用或轨迹参数。接口越低层，训练数据越依赖具体本体和控制频率；接口越高层，越依赖可靠的技能库和规划器。没有“天然最统一”的动作空间。

RT-1 展示了语言/视觉条件下的大规模真实机器人动作 token 学习^[2]。但输出动作仍要经过单位还原、限幅、安全过滤和低层控制。接触任务还需力/触觉反馈和恢复状态机；模型生成“向下 2 cm”并不能证明下方无障碍或插孔已对齐。

表 16.1: VLM 能力向 VLA 迁移时的证据缺口

已有能力	可迁移用途	仍缺信息	必要验证
开放词汇识别	找到语言目标候选	三维姿态、实例持续性	遮挡/同类实例 grounding
关系与常识	任务分解、候选技能	本体可达、动态约束	当前状态的可供性
语言生成	解释或规划草案	动作单位与控制周期	编译到技能/动作接口
视觉问答	描述场景与异常	接触力、隐蔽几何	触觉/状态闭环
长序列建模	使用历史条件	状态新鲜度、错误记忆	延迟、恢复和回滚一致性

16.4 安全门与失败恢复

VLA 的动作提议应与执行分离。执行前检查状态新鲜度、坐标/单位、关节/速度边界、碰撞和任务权限；执行中监控接触、超时和偏差；执行后验证预期状态是否发生。验证失败要触发重观测、撤回或请求人工，而不是无条件进入下一个语言步骤。

Listing 16.1: 语义动作到可执行命令的安全门教学伪代码

```
1 proposal = vla.predict(observation, instruction, embodiment)
2 command = action_adapter.decode_units_frames(proposal)
3 if stale(observation) or not affordance_model.feasible(command):
4     return reobserve_or_replan()
5 if not collision_and_limit_check(command):
6     return safe_reject(reason="physical_constraint")
7 result = low_level_controller.execute(command, monitors=contact_limits)
8 if not verify_expected_state(result): recover_or_request_help()
```

安全过滤后的实际动作必须回写历史，否则模型以为自己的提议已执行，下一步条件错误。过滤频率高也说明策略与可行域不匹配，不能把安全层拦截当作部署成功。

16.5 与 VLA 系统综述的边界

本章只建立必要接口：语义先验、grounding、本体状态、动作表示和闭环验证。第 22 章建立统一分类，第 23 章比较代表性模型，第 24 章讨论数据/训练/泛化，第 25 章核验开源复现。这里不按模型逐一写架构和排行榜，避免同一论文在基础章与综述章重复介绍。

16.6 知识小结与综述判断

知识小结：VLM 可迁移开放词汇语义、关系和语言组合先验；VLA 还必须加入 grounding、本体状态、动作接口、物理约束和执行后验证。语言相关性与机器人可供性是不同信号。

综述判断：从“看懂”到“做对”的缺口不是再加一个动作头即可填平，而是整条闭环接口。模型论文若只报告语义任务或离线动作准确率，不能证明具身能力；真机证据应说明实际执行动作、低层控制、安全拦截和失败恢复，否则无法判断能力来自模型还是外部系统。

第十七章 上下文、外部记忆与长时程任务

17.1 三种时间尺度需要三种状态

长时程任务不能把所有历史帧无限塞进上下文。高频物理状态服务控制，保留毫秒到秒；技能级事件记录“抓取失败、已重定位”，保留分钟；任务级状态记录目标、已完成步骤、资源与权限，可跨会话持久化。三者更新频率、可信度和写入权限不同。




图 17.1: 长时程机器人记忆的三层结构。作者教学绘制；事件摘要不能覆盖实时状态，任务状态也不能由自由文本独占。

纯长上下文把历史 token 留在模型窗口，保真但成本随长度增加；外部检索只取相关片段，扩展容量但可能漏召回或污染；结构化任务状态用 schema 保存关键变量，可验证但表达灵活性较低。工程系统通常组合三者。

17.2 历史压缩、事件摘要与检索

摘要把长轨迹压成短文本或 latent。压缩必须保留任务所需事实、来源和不确定性。只写“抓取失败”不够，应记录对象 ID、姿态、夹爪命令、接触/视觉证据、失败分类和恢复动作。摘要模型可能把“不确定”改写成确定陈述，因此应链接原始事件包。

检索分数可组合语义、时间和任务过滤：

$$S(m_i, q, t) = \alpha \text{sim}(e(m_i), e(q)) - \beta(t - t_i) + \gamma \mathbf{1}[\text{task}(m_i) = \text{task}(q)]. \quad (17.1)$$

时间衰减不应统一：安全禁令可能长期有效，瞬时位姿几百毫秒即过期。RAG 展示了参数模型结合外部检索的基本框架^[10]；机器人还需物理时间、坐标系和设备版本过滤。

ReAct 把推理轨迹与外部动作/观察交错^[11]，为工具调用和事件写入提供了组织方式。但自由文本思考不应作为唯一控制状态；模型可改写或遗漏先前结论，且文本没有强类型约束。

17.3 结构化任务状态与恢复

任务状态可写成有限状态机、行为树 blackboard 或事件溯源记录。状态转移应由可验证事件触发：

$$z_{k+1} = \delta(z_k, e_k), \quad e_k = (\text{type}, \text{time}, \text{evidence}, \text{version}). \quad (17.2)$$

若状态为 INSERTING，只有深度、力和视觉共同满足成功条件才转到 VERIFIED；单一语言模型判断不应覆盖硬传感条件。

恢复必须区分“恢复软件上下文”和“恢复物理状态”。进程重启后数据库可能记得物体已抓取，但机器人实际因断电松爪。系统应重新观测关键不变量，再决定从哪个技能继续。任务状态需包含模型/地图/标定版本，回滚模型时同步检查记忆兼容性。

Listing 17.1: 带版本、来源与过期检查的记忆读写教学伪代码

```

1 event = observe_skill_result(raw_sensors, controller_log)
2 memory.append(event, source_links=raw_bundle,
3               map_version=map.id, calibration=calibration.id)
4 task_state = transition(task_state, verified(event))
5
6 candidates = memory.retrieve(query, task_id=task_state.task_id)
7 usable = [m for m in candidates
8           if not expired(m) and compatible_versions(m, current_system)]
9 context = compose(recent_physical_state(), usable, task_state)
10 if critical_invariant_unknown(context): reobserve_before_acting()
```

17.4 上下文预算与写入治理

上下文窗口应给当前观测、任务指令、检索历史和动作输出分别预算。若检索片段挤占当前图像 token，模型可能“记得过去却看不见现在”。可先保留不可压缩的当前状态和安全规则，再按得分选择事件，最后留出输出空间。

外部记忆还需要写入权限。传感器事实、控制执行结果、操作者备注和模型推断应使用不同字段；推断不能覆盖事实。错误信息若被模型生成、写入、再次检索，会形成自我强化污染。关键事件应需要规则或人工确认。

表 17.1：长上下文、检索记忆与结构化状态的职责比较

方式	优点	代价	典型风险	适用信息
纯长上下文	保留原始细节、实现直接	计算/内存随长度增长	位置稀释、窗口截断	最近对话、短轨迹
摘要上下文	token 少、可读	压缩不可逆	幻觉、遗漏不确定性	技能结果概述
外部向量检索	容量大、按需读取	索引和检索链复杂	漏召回、污染、陈旧	历史案例、文档
结构化任务状态	强类型、可验证、易恢复	schema 设计成本	schema 不全、迁移失败	步骤、权限、不变量
事件溯源	可审计、可重放	日志量与重建成本	事件顺序/版本错误	控制与任务关键事件

17.5 错误记忆与长时程评测

评测应主动注入：过期位姿、错误对象 ID、矛盾摘要、缺失恢复事件、地图版本变化和检索无关片段。指标包括关键事实召回、错误记忆采纳率、恢复后状态一致性、上下文延迟和任务成功。只在干净历史上跑长任务，无法证明系统能抵抗记忆污染。

语言模型可帮助解释和检索，但安全关键不变量应由结构化状态和传感证据维护。SayCan 等系统把高层语言规划与可执行技能结合^[9]；长时程扩展仍需明确技能结果怎样写回、失败怎样影响后续候选。

17.6 知识小结与综述判断

知识小结：高频状态、事件记忆和任务状态对应不同时间尺度；长上下文保留细节，检索扩展容量，结构化状态提供可验证持久化。摘要、检索和状态转移都必须携带来源、时间与版本。

综述判断：机器人记忆不是“更长 prompt”，而是状态治理。真正危险的不是忘记一段描述，而是把过期或推断性信息当成当前物理事实。长时程系统的证据应包括断点恢复、版本回滚和错误记忆注入测试，而不只展示一次成功的长链推理。

References

- [1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need [C/OL]//Advances in Neural Information Processing Systems: vol. 30. 2017 [2026-07-14]. <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>.
- [2] BROHAN A, et al. RT-1: Robotics Transformer for Real-World Control at Scale[J/OL]. arXiv preprint arXiv:2212.06817, 2022. DOI: [10.48550/arXiv.2212.06817](https://doi.org/10.48550/arXiv.2212.06817).
- [3] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale[C/OL]//International Conference on Learning Representations. 2021 [2026-07-14]. <https://openreview.net/forum?id=YicbFdNTTy>.
- [4] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision[C/OL]//Proceedings of the 38th International Conference on Machine Learning: vol. 139. 2021: 8748-8763 [2026-07-14]. <https://proceedings.mlr.press/v139/radford21a.html>.
- [5] YUAN W, DONG S, ADELSON E H. GelSight: High-Resolution Robot Tactile Sensors for Estimating Geometry and Force[J/OL]. Sensors, 2017, 17(12): 2762. DOI: [10.3390/s17122762](https://doi.org/10.3390/s17122762).
- [6] JAEGLE A, GIMENO F, BROCK A, et al. Perceiver: General Perception with Iterative Attention[C/OL]//Proceedings of the 38th International Conference on Machine Learning: vol. 139. 2021: 4651-4664 [2026-07-14]. <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [7] LI J, LI D, SAVARESE S, et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models [C/OL]//Proceedings of the 40th International Conference on Machine Learning: vol. 202. 2023: 19730-19742 [2026-07-14]. <https://proceedings.mlr.press/v202/li23q.html>.

- [8] DRIESS D, et al. PaLM-E: An Embodied Multimodal Language Model [J/OL]. arXiv preprint arXiv:2303.03378, 2023. DOI: [10.48550/arXiv.2303.03378](https://doi.org/10.48550/arXiv.2303.03378).
- [9] AHN M, BROHAN A, BROWN N, et al. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances[J/OL]. Conference on Robot Learning, 2023, 205: 287–318 [2026-07-14]. <https://proceedings.mlr.press/v205/ahn23a.html>.
- [10] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C/OL]//Advances in Neural Information Processing Systems: vol. 33. 2020: 9459–9474 [2026-07-14]. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [11] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C/OL]//International Conference on Learning Representations. 2023 [2026-07-14]. https://openreview.net/forum?id=WE_vluYUL-X.